AGENT HARNESS / 01

工具可用，调用有界。

2.19.1

学习助手后端
轻量工具循环

接入现有 AI 对话：按需查询词库、计算与读取材料，再根据真实结果回答。保留账户隔离、每日预算和学习动作校验。

一条明确的执行路径

Cloudflare Worker · TypeScript

01 / REQUEST

验证请求与上下文

同源与身份检查；按来源开关读取资料与学习上下文。

→

02 / MODEL

模型选择下一步

直接回答，或提出结构化工具请求；每轮预留并结算 token。

→

03 / TOOLS

执行、校验、返回

工具名与参数白名单；返回有界结果；最终答案校验后交给界面。

工具结果返回下一轮模型。普通问答保持一次模型请求；取消、额度不足或达到上限时结束循环。

3 次模型生成上限	6 次工具调用上限	300s 整轮时间上限

首批四个工具

只读 · 确定性执行 · 有界输出

词库检索 `search_lexicon`

查询已发布词条，返回稳定 ID、释义与出处，结果可用于学习操作卡。

算术计算 `calculate`

解析基础算术表达式，服务于词数、时间与学习任务计算。

文本统计 `text_stats`

统计提供文本的词数、句数等指标，帮助判断篇幅。

所选资料读取 `read_source`

按位置读取本轮已提供的文章、文件和引用，限制每次摘录长度。

设计参考

Codex App Server：统一模型与工具执行循环。
Claude Agent SDK：轮次、预算、取消与执行边界。
DeepSeek Harness：显式能力注册、统一工具管线。

依据官方文档与公开仓库；详细链接与项目取舍见 docs/HARNESS_REFERENCES.md。

PERFORMANCE & VERIFICATION / 02

减少无效分配，保留可核对的证据。

02

2 MiB ASCII 附件 / UTF-8 解码中位数

50.27 → 2.36 ms

固定输入，15 次交错采样。混合 Unicode 附件：29.24 → 4.10 ms；相同采样方法。

去除全文字符数组分配；统一附件长度边界。
保留完整 emoji，截断结果符合服务端 12,000 长度上限。

本次验证

仅列本轮实际执行结果

01 **类型、静态与生产产物** 通过

TypeScript、ESLint、生产构建与产物校验通过；数据审计通过，既有词库缺项保留记录。

02 **单元与回归覆盖** 89 文件

89 个测试文件已覆盖：87 个首次通过；性能历史 6 项、供应链 3 项定向复验通过。

03 **新工具与对话入口** 通过

Harness 11 项、工具箱 6 项、附件边界 3 项、对话入口 3 项通过。覆盖取消、超限、错误参数与正常调用。

04 **Worker、D1 与独立复核** 通过

本地 Worker / D1 运行时检查通过；独立复核无阻塞项。本次无数据库迁移，线上 10 张预期表已核对。

交付与发布

代码与报告进入本次 PR 和 Sites 发布包。报告生成时，发布及 PR 创建待执行。

词迹 · 既有站点入口

验证范围

AI 使用受控返回，未调用付费模型。托管预览监听遇到 EPERM，浏览器交互检查未完成。

复现：node --import ./tests/register.mjs scripts/benchmark-attachments.mjs。Node v24.22.1 本地微基准；不含浏览器 I/O、文档提取与模型延迟。原始数据：attachment-benchmark.json。

对照基线：d148c35。两项定向复验分别在独立进程与获准的外层环境完成；性能历史用例 95.03 ms，阈值 150 ms。